

D-MTHD প্রকল্প: Phase 2 থেকে আজ পর্যন্ত

Team briefing · ২০ সেপ্টেম্বর ২০২৬ · BRAC University CSE thesis, “A Dynamic Multi-Teacher Homogeneous Knowledge Distillation Framework for Robust Cyberbullying Detection” থেকে Q1 journal paper-এর দিকে যাত্রা। প্রতিটি সংখ্যা repository-র DECISIONS.md, LOG.md আর Kaggle-এর run থেকে নেওয়া।

সূচি

১. এক নজরে, আর কয়েকটা শব্দের সহজ মানে
২. Phase 2 পেপারে কী ছিল, কী সমস্যা পেয়েছিলাম
৩. Phase 2 বনাম এখন: কী কী বদলেছি
৪. যে dataset-গুলো ব্যবহার করেছি, আর কেন
৫. যে model-গুলো ব্যবহার করেছি, আর কেন
৬. পদ্ধতি (D-MTHD) সহজ ভাষায়, আর মাপকাঠি
৭. নেওয়া সিদ্ধান্তগুলো (D1–D19), প্রতিটার কারণ
৮. Kaggle-এ চালানোর ইতিহাস (V1–V4, সামনের V5)
৯. ফলাফল, সংখ্যাসহ
১০. কেন কাজ করেনি: মাপা কারণ (mechanism)
১১. সব finding এক নজরে (F1–F30)
১২. যা পারিনি (সং তালিকা)
১৩. নতুন কী দিতে পারছি (novelty)
১৪. পেপারের framing, আর এখন যে পথে হাঁটিছি (transfer set)
১৫. Q1 journal-এর জন্য কী লাগে, কোথায় আছি, ঝুঁকি
১৬. সামনের কাজ, আর team-এর কাছে যা দরকার
১৭. কোথায় কী আছে (repository)

১. এক নজরে

কোথা থেকে শুরু। Phase 2-এর দাবি ছিল: কয়েকজন বড় teacher model-এর জ্ঞান “dynamic weighting” দিয়ে একটা ছোট student model-এ ঢালা যায়, আর তাতে cyberbullying detection ভালো হয়। কিন্তু Phase 2-এর নিজের সংখ্যাই উল্টো কথা বলছিল: teacher ছাড়া সাধারণভাবে train করা DistilBERT পেয়েছিল 0.859 macro-F1, আর D-MTHD student পেয়েছিল 0.830। অর্থাৎ distillation ক্ষতি করছিল, আর সেটা কেউ খেয়াল করেনি।

কী করেছি। ডেটা পরিক্ষার করেছি, একটা নতুন benchmark বানিয়েছি যেখানে “ইঙ্গিতে করা abuse” আলাদা label, ৫টা teacher আর ৫টা student নিয়ে ১৩১টা run চালিয়েছি (৩টা seed করে), আর প্রতিটা দাবি একটা control-এর বিপরীতে মেপেছি (teacher ছাড়া একই student)। মোট ৬৬টা পরিসংখ্যানগত তুলনা করেছি।

মূল ফল, পাঁচ লাইনে

১. Distillation পাঁচটা student-এরই score একটু বাড়ায় (+0.001 থেকে +0.007), কিন্তু কোনোটাই পরিসংখ্যানগতভাবে প্রমাণিত নয়। একমাত্র যে পার্থক্য প্রমাণিত, তা হলো pre-training সরালে -0.047।
২. Dynamic weighting সাধারণ গড়ের (uniform averaging) চেয়ে ভালো নয়, temperature 0.05 থেকে 5 পর্যন্ত কোনো মানেই।
৩. ইঙ্গিতপূর্ণ abuse শেখা একটা specialist teacher যোগ করেও লাভ হয়নি; একা ব্যবহার করে বা pre-training করেও না।
৪. কেন হয়নি, তা মাপা গেছে: teacher-রা training data মুখস্থ করে ফেলে (loss 0.03–0.08), তাই reliability signal-এর কিছু মাপার থাকে না; task-এ মানিয়ে নেওয়ার পর teacher-রা প্রায় একই রকম হয়ে যায় (kappa 0.89–0.96); committee-র যে +0.5 থেকে +0.8 পয়েন্ট লাভ আছে, student তা পায়ই না।

5. ইঙ্গিতপূর্ণ abuse আর নির্দোষ sarcasm আলাদা করার ক্ষমতা pre-training-এই বাঁধা: ২৫ রকম student-এর AUC 0.756–0.777-এর মধ্যে আটকে, শুধু pre-training সরালে নামে 0.613-এ।

এখন কোথায়। দুটো পথ পাশাপাশি চলছে। (ক) যা মাপা হয়ে গেছে তা দিয়ে একটা পূর্ণ পেপার তৈরি আছে git branch paper-b2-audit-এ: “Distillation Does Not Teach Implication”, একটা negative result যার mechanism মাপা। (খ) Mahdi-র সিদ্ধান্ত অনুযায়ী positive result-এর জন্য একটা নতুন পরীক্ষা তৈরি: unlabelled tweet-এর একটা transfer set-এ distillation, যেখানে teacher-রা কিছু মুখস্থ করেনি। এটা Kaggle-এ পরের run (V5)-এ চলবে; কী হবে সেটার prediction আগেই লিখে রাখা আছে।

Team-এর কাছে যা দরকার: implicit benchmark-এর notebook চালানো, annotation sheet ফেরত, framing-এর সিদ্ধান্ত, আর venue ঠিক করা। বিস্তারিত ১৬ নম্বর অংশে।

১.১ কয়েকটা শব্দের সহজ মানে

Teacher	বড় model, যাকে task-এ fine-tune করে জমিয়ে (freeze) রাখি; তার output দিয়ে ছোট model শেখে।
Student	ছোট model, যেটা আসলে ব্যবহার হবে (কম memory, কম সময়)।
Knowledge distillation (KD)	Student-কে শুধু সঠিক label নয়, teacher-এর “soft” probability-ও নকল করতে শেখানো।
Committee / multi-teacher	একাধিক teacher-এর output মিলিয়ে student-কে শেখানো। Uniform মানে সবাইকে সমান weight; dynamic (per-instance) মানে প্রতিটা উদাহরণে যে teacher বেশি নির্ভরযোগ্য তাকে বেশি weight। দ্বিতীয়টাই D-MTHD-র মূল দাবি ছিল।
Fine-tune only (ft)	Teacher ছাড়া student-কে সরাসরি train করা। এটাই আমাদের control: distillation এর চেয়ে ভালো না করলে distillation-এর দাম নেই।
Macro-F1	প্রতিটা class-এর F1-এর গড়। Class-এর আকার অসমান হলেও ন্যায্য।
AUC (threshold-free)	কোনো cut-off ছাড়াই model positive-কে negative-এর ওপরে rank করতে পারে কি না। 0.5 মানে আন্দাজ, 1.0 মানে নিখুঁত।
Seed	Random শুরু। একই setting তটা seed-এ চালিয়ে গড় নিই, যাতে ফল কাকতালীয় না হয়।
Paired bootstrap, 95% CI	Test set-কে ১,০০০ বার resample করে দুই model-এর পার্থক্যের interval। Interval-এ ০ থাকলে পার্থক্য প্রমাণিত নয়।
Ablation	Method-এর একটা অংশ সরিয়ে দেখা সেটা কতটা কাজ করছিল।
Probe set	শুধু test-এর জন্য আলাদা ছোট set (যেমন নির্দোষ sarcasm)। কখনো train-এ যায় না।
Implicit / indirect abuse	গালি ছাড়া, ইঙ্গিতে, বিদ্রোপে বা stereotype দিয়ে করা আক্রমণ। পেপারের মূল লক্ষ্য।

২. Phase 2 পেপারে কী ছিল, কী সমস্যা পেয়েছিলাম

Phase 2 report (ফেব্রুয়ারি ২০২৬): Wikipedia Talk personal-attacks corpus; teacher BERT-large আর RoBERTa-base; student DistilBERT; একটা seed; একটা dataset; বাইরের কোনো baseline নেই; efficiency-র সংখ্যা নেই। শিরোনামে “dynamic”, “homogeneous” আর “robust” তিনটাই দাবি, কিন্তু কোনোটা মাপা নয়।

Phase 3-এর শুরুতে (সেপ্টেম্বর, Drive folder-এর কাজ): team tweet corpus-এ (Wang et al. 2020, ৬ class) সরে এসেছিল। সেখানে তিনটা teacher (BERT-base general, BERT-base “implicit”, RoBERTa-base) পেয়েছিল 0.819–0.828। Teacher ছাড়া DistilBERT পেয়েছিল **0.859**, আর D-MTHD student **0.830**। এর মানে: teacher-রা student-এর চেয়ে দুর্বল ছিল, আর distillation তিন পয়েন্ট ক্ষতি করেছিল।

আরও যে সমস্যা পেয়েছিলাম (১০–১১ সেপ্টেম্বর):

- Validation accuracy 0.94 কিন্তু test 0.86: এই ফারাকের কারণ duplicate tweet, যা train আর validation দুই জায়গাতেই ছিল (leakage)। Test set-এ ৮৪টা ছবছ duplicate, তার ৫৭টার label-ও পরস্পরবিরোধী।
- Dynamic weight আটকে ছিল [0.08, 0.64, 0.28]-এ। মানে committee কার্যত একজন teacher।
- Latency-র সংখ্যা ব্যবহারযোগ্য ছিল না: দুটো একই আকারের BERT-base teacher-এর latency 2.5 গুণ আলাদা এসেছিল।
- Method-টা MT-BERT (Wu et al. 2021)-এর প্রায় অনুরূপ: error-weighted soft label + projected hidden-state alignment। Reviewer-এর কাছে এটাই সবচেয়ে বড় ঝুঁকি।

- Reference list-এ duplicate entry, একটা ভুল citation (“Luo et al.”), URL আর venue-র অমিল।

সবচেয়ে গুরুত্বপূর্ণ পরিণতি

এরপর থেকে প্রকল্পের প্রতিটা দাবি একটা control-এর বিপরীতে মাপা হয়: teacher ছাড়া একই student। Phase 2-তে এই control না থাকাতেই “কাজ করে” মনে হয়েছিল।

৩. Phase 2 বনাম এখন: কী কী বদলেছি

বিষয়	Phase 2 (ফেব্রুয়ারি) / Phase 3-এর শুরু	এখন (২০ সেপ্টেম্বর)
Corpus	একটা (Wikipedia); পরে tweets, না পরিষ্কার করে	Tweets পরিষ্কার করে; Wikipedia প্রস্তুত; নিজেদের বানানো implicit benchmark; ISHate out-of-domain test; ৩টা probe set; transfer set
Teacher	২টা (BERT-large, RoBERTa-base) / ৩টা BERT-base	৫টা task-adapted: BERT-large, HateBERT, RoBERTa-irony, DeBERTa-v3-base, implicit specialist
Student	শুধু DistilBERT	৫টা, 10M থেকে 71M: BERT-mini (headline), BERT-small, DistilBERT, DeBERTa-v3-xsmall, BiLSTM
Control	নেই	প্রতিটা student-এ fine-tune-only; TF-IDF classical floor; পরে ২টা specialist control
Seed	১	৩ (ablation-এ ১)
Statistics	নেই	Paired bootstrap 95% CI, ৬৬টা তুলনা, generated table
Implication-এর মাপকাঠি	নেই / recall@0.5	Threshold-free sarcasm-discrimination AUC আর implicit-discrimination AUC
Committee	১	৩ (homogeneous, + specialist, + DeBERTa)
Ablation / sweep	নেই	৭টা ablation; τ (৭ মান), T , α , δ sweep
Efficiency	ব্যবহারযোগ্য নয়	Latency (batch 1/32), FLOPs, INT8 quantisation, size
Robustness	দাবি	Obfuscation ৪ রকম, cross-corpus transfer, মাপা
Reproducibility	নেই	Public repo, fixed seed, per-row manifest, lab notebook, সব table কোড থেকে
দাবির ধরন	“কাজ করে”	যা মাপা গেছে তাই; negative হলে negative, mechanism সহ

8. যে dataset-গুলো ব্যবহার করেছি, আর কেন

Dataset	Size (train / val / test)	কেন, আর অবস্থা
Cyberbullying tweets (Wang et al. 2020)	34,607 / 4,326 / 4,326	Primary benchmark। ৬ class: age, ethnicity, gender, religion, other_cyberbullying, not_cyberbullying। ইঙ্গিতপূর্ণ abuse বেশিরভাগ “other” class-এ লুকিয়ে থাকে। অবস্থা: Kaggle-এ পূর্ণ grid শেষ (১৩১ run)।
Wikipedia Talk personal attacks (Wulczyn et al. 2017)	68,750 / 22,782 / 22,721	দ্বিতীয় corpus; প্রতিটা comment-এ ~১০ জন annotator-এর vote আছে, তাই “annotator-রা দ্বিমত করলে student কাকে বিশ্বাস করবে” সেই variant এখানেই মাপা যায়। Attack 11.7%; 24.6% comment-এ annotator-রা দ্বিধায়। অবস্থা: শুধু laptop-এ চলেছে; Kaggle grid বাকি।
Implicit benchmark (Implicit Hate Corpus stage 1, ElSherief et al. 2021)	16,509 / 2,064 / 2,064	আমরা নিজেরা বানিয়েছি। তিনটার মধ্যে একমাত্র corpus যেখানে “ইঙ্গিতে abuse” একটা label, লুকানো subset নয়। Class: not_hate 10,616, implicit_hate 5,029, explicit_hate 864 (train)। অবস্থা: specialist, একটা student আর floor চলেছে; পূর্ণ student grid বাকি।
ISHate (Ocampo et al. 2023)	27,096 (test only)	Out-of-domain test set, পুরোটাই training-এর বাইরে। Implicit benchmark-এ train করা model অন্য domain-এ কেমন করে, সেটা মাপার জন্য। অবস্থা: এখনো evaluate হয়নি।
Probe: benign sarcasm (iSarcasmEval)	1,064 (screening-এর পর 883)	Sarcasm যা কাউকে আক্রমণ করে না। মাপি: model এগুলোকে ভুল করে abuse বলে কি না (false-positive rate)।
Probe: ironic abuse	1,560	বিদ্রূপ দিয়ে করা abuse (IHC-র 797 irony post + ISHate-এর 763 implicit row)। মাপি: recall, আর ওপরের set-এর সঙ্গে মিলিয়ে AUC।
Probe: implicit abuse	763	ISHate-এর implicit row-গুলো একা। Recall।
Transfer set (নতুন, V5-এর জন্য)	42,013 (unlabelled)	OLID, HatEval, Davidson corpus-এর tweet শুধু text হিসেবে (label ফেলে দিয়ে), আর আমাদের বাদ দেওয়া 1,563টা পরস্পরবিরোধী-label tweet। সব split, probe আর implicit benchmark-এর সঙ্গে dedupe করা। ১৪ নম্বর অংশে কেন।

Tweet corpus পরিষ্কার করা (D1)। মূল corpus-এ 47,692 tweet। ৭৫৮টা দুই token-এর ছোট, 1,563টা text একাধিক label নিয়ে এসেছে (মোট 3,168 row), আর ৫০৭টা ছবছ duplicate। এগুলো সরিয়ে 43,259 tweet 80/10/10-এ ভাগ (seed 42), আর নিশ্চিত করা হয়েছে তিন split-এ কোনো text মেলে না। এরপর validation আর test-এর ফারাক (0.94 বনাম 0.86) মিলিয়ে গেছে। যে দুটো class সবচেয়ে বেশি row হারিয়েছে (other_cyberbullying আর not_cyberbullying), সেগুলোই literature-এ “গুলিয়ে যাওয়া” class।

Implicit benchmark কেন একটা corpus থেকে (D17)। দুটো corpus implication label করে: IHC আর ISHate। দুটো মেশালে একটা ফাঁদ তৈরি হয়: ৯৫% implicit উদাহরণ আসে IHC থেকে আর ৮৯% explicit আসে ISHate থেকে, আর একটা সাধারণ TF-IDF classifier কোন text কোন corpus-এর তা 0.91 macro-F1-এ চিনে ফেলে। ফলে model implication না পড়েও উৎস চিনে নম্বর পেতে পারে। প্রমাণ: একই IHC test row-এ, মেশানো ডেটায় train করা model implicit hate-এ পায় 0.473 F1, একা IHC-তে train করা model পায় 0.548; অথচ মেশানো ডেটার সামগ্রিক নম্বর বেশি (0.681 বনাম 0.562)। এটাই ফাঁদ। তাই IHC একা, ISHate পুরোটা বাইরে।

Label নিজেই বিতর্কিত (F14)। দুই corpus-এর ৬২৯টা text এক। কোনটা hateful, তাতে দুই দল একমত 99.7%। কিন্তু hate-টা সরাসরি না ইঙ্গিতে, তাতে একমত মাত্র 48.2%। এই সংখ্যা আমাদের সব implicit ফলের সীমা টেনে দেয়, আর এজন্যই headline metric একটা threshold-free ranking, একটা decision নয়।

Probe-গুলো বাদ দেওয়া (D16)। Probe-এর প্রতিটা text implicit benchmark-এর তিন split থেকেই মুছে ফেলা হয়েছে (1,581 row), যাতে কোনো model কখনো probe-এর text-এ train না করে।

৫. যে model-গুলো ব্যবহার করেছি, আর কেন

ভূমিকা	Model	Params	Tweets macro-F1	কেন
Teacher	BERT-large-uncased	335M	0.8973	সাধারণ, শক্তিশালী encoder; committee-র "general" সদস্য।
Teacher	HateBERT (Reddit-এর abusive text-এ pre-trained)	~110M	0.8887	সরাসরি গালি/abuse-এর specialist।
Teacher	Twitter-RoBERTa-irony (Cardiff)	~125M	0.8926	Irony/sarcasm-এর specialist। এর নিজের label (irony/না) আলাদা, তাই student-এ একটা আলাদা "irony head"-ও দেওয়া হয় (D4)।
Teacher (hetero)	DeBERTa-v3-base	~184M	0.8720	অন্য architecture family; "homogeneous" ব্যাপারটা আদৌ কিছু বদলায় কি না মাপার জন্য (D7)।
Teacher (specialist)	Implicit specialist = HateBERT, আগে implicit benchmark-এ train, তারপর tweets-এ adapt	~110M	0.8931	Committee-র একমাত্র সদস্য যে "ইঙ্গিতে abuse" label করা দেখেছে (D14)।
Student (headline)	BERT-mini	11.2M	0.8393	সত্যিই ছোট; deploy করার মতো। মূল দাবি এটার ওপর।
Student	BERT-small	28.8M	0.8469	আকারের curve-এর মাঝের বিন্দু।
Student	DistilBERT	67.0M	0.8907	Phase 2-এর student; efficiency দাবি এটাতে।
Student (hetero)	DeBERTa-v3-xsmall	70.8M	0.8825	অন্য transformer family।
Student (hetero)	BiLSTM (২ layer, WordPiece vocab)	10.4M	0.8693	Transformer-ই নয়; homogeneity-র সবচেয়ে কড়া পরীক্ষা।
Floor	TF-IDF (word 1-2 gram + char 3-5 gram) + logistic regression	—	0.8798	Classical baseline। এটাকে না হারালে GPU-র দাম নেই।

Student-এর কলামে teacher ছাড়া fine-tune করা model-এর ৩ seed-এর গড়। প্রতিটা teacher একবার train (৫ epoch, lr 2e-5), তারপর freeze; output একবার cache করে student-রা ব্যবহার করে।

বড় teacher, ছোট student কেন (D2)। Phase 2-তে teacher আর student প্রায় একই আকারের ছিল, তাই শেখানোর কিছু ছিল না। এখন 335M teacher বনাম 11M student: শেখার জায়গা আছে, আর ফলটা বাস্তব প্রশ্নের উত্তর দেয় ("phone-এ চলার মতো model কি বড় model-এর কাছাকাছি যেতে পারে?")।

Cross-task specialist কেন (D3)। তিনটা একই রকম teacher-এর বদলে তিন রকম দক্ষতা: general, abuse, irony। ধারণা ছিল, যার যে দক্ষতা, weighting তাকে সেখানে বেশি ভরসা করবে। এই ধারণাটাই পরে মাপা হয়ে ভুল প্রমাণিত হয়েছে (১০ নম্বর অংশ)।

৬. পদ্ধতি (D-MTHD) সহজ ভাষায়, আর মাপকাঠি

ধাপ ১, task adaptation: প্রতিটা teacher-কে tweet corpus-এ fine-tune করা হয়, যাতে সবার output একই ৬টা class-এ আসে। (Irony model-এর label irony/না, HateBERT-এর label নেই; adapt না করলে এদের output মেলানোই যায় না।) তারপর teacher freeze, আর training split-এর প্রতিটা tweet-এ তার logits আর hidden state একবার cache করা হয়।

ধাপ ২, student-এর loss: চারটা অংশের যোগ।

- **CE:** সঠিক label শেখা (সাধারণ training)।
- **KL:** committee-র soft probability নকল করা। Committee-র output = প্রতিটা teacher-এর softmax-এর weighted গড়।
- **Hidden:** student-এর hidden state-কে projection দিয়ে প্রতিটা teacher-এর hidden state-এর কাছে আনা।
- **Irony head:** student-এর একটা extra head, যা frozen irony teacher-এর output নকল করে; inference-এ ফেলে দেওয়া হয়।

Dynamic weight: প্রতিটি উদাহরণ i -তে teacher k -এর weight $w_k(i) = \text{softmax}(-CE_k(i)/\tau)$ । মানে যে teacher ওই উদাহরণে সঠিক label-কে বেশি probability দেয়, সে বেশি weight পায়; τ ছোট হলে weight তীক্ষ্ণ (প্রায় একজনকে বাছ), বড় হলে সমান। Teacher frozen বলে এই weight ডেটার একটা fixed function: epoch বা seed বদলালে বদলায় না। Wikipedia-র জন্য একটা variant আছে যেখানে annotator-রা দ্বিমত করলে student label-এর চেয়ে committee-কে বেশি বিশ্বাস করে (এখনো চলনি)।

মাপকাঠি বদলানো (D13)। প্রথমে আমরা “ironic abuse-এ recall” মাপতাম। কিন্তু একটা model recall বাড়াতে পারে শুধু বেশি বেশি “abuse” বলে দিয়ে, তখন নির্দোষ sarcasm-ও abuse হয়ে যায়। তাই headline metric এখন **sarcasm-discrimination AUC**: ironic abuse-কে positive আর benign sarcasm-কে negative ধরে model-এর $p(\text{abusive})$ দিয়ে rank করলে AUC কত। এটা threshold-free, তাই “দেখতে পায় না” আর “দেখে কিন্তু আলাদা করতে পারে না” এই দুইকে আলাদা করে। Implicit benchmark-এ একই ধারণা: implicit-discrimination AUC (implicit hate বনাম not hate)।

৭. নেওয়া সিদ্ধান্তগুলো (D1-D19), প্রতিটার কারণ

#	সিদ্ধান্ত	কেন
D1	আগে ডেটা পরিষ্কার, তারপর সব	Duplicate আর পরস্পরবিরোধী label-ই Phase 2-এর ফল বিকৃত করেছিল।
D2	বড় teacher, ছোট student	একই আকারে distillation-এর শেখানোর কিছু থাকে না; ছোট student-ই বাস্তব প্রশ্ন।
D3	Cross-task specialist committee	ভিন্ন দক্ষতার teacher থাকলে weighting-এর বাছার কিছু থাকে (ধারণা; পরে ভুল প্রমাণিত)।
D4	Irony teacher committee-তে নয়, আলাদা auxiliary head	তার label space আলাদা; KL term-এ ঢোকানো যায় না।
D5	Per-instance weight, standard KL, T^2 scaling	Literature-এর প্রচলিত ও তুলনাযোগ্য রূপ।
D6	৩ seed; ablation-এ ১	GPU budget-এর ভেতরে যতটা নির্ভরযোগ্য হওয়া যায়।
D7	“Homogeneous” novelty নয়, মাপার বিষয়	এটা distillation-এর সাধারণ setting; দাবি করলে reviewer ধরবে। তাই DeBERTa teacher, DeBERTa/BiLSTM student আর hidden-term ablation দিয়ে মাপা।
D8	বাংলা thesis-এ, Q1 পেপারে নয়	বাংলা sarcasm teacher নেই; scope আলাদা রাখা।
D9	“Robust” শিরোনামে থাকবে না, যদি না মাপা হয়	মাপা হয়েছে: obfuscation-এ ১২-১৩ পয়েন্ট পড়ে; দাবি টেকে না।
D10	ব্যর্থতা লুকানো নয়, report করা	Control-এর কাছে হারলে সেটাই ফল; reviewer লুকানো জিনিস ধরলে সব দাবি অবিশ্বাস্য হয়।
D11	Single-teacher KD committee-প্রতি একবারই	একই কাজ বারবার করে GPU নষ্ট নয়।
D12	সতর্ক থাকার বদলে কোডে guard	Cache/split mismatch, collapsed teacher, resume—সব automatic check।
D13	Headline metric: discrimination AUC, recall@0.5 নয়	Recall শুধু “কত সহজে abuse বলে” মাপে (F19 প্রমাণ)।
D14	Implication-এ শুধু test নয়, train-ও	কোনো corpus বা teacher implication label করা দেখেনি; তাই তৃতীয় benchmark আর specialist।
D15	Specialist আলাদা committee (spec), homo-তে ঢোকানো নয়	আগের ১০ GPU-ঘণ্টার run বৈধ থাকে; তুলনাটা ৩ seed-এর হয়।
D16	Probe text implicit benchmark থেকে মুছে ফেলা	Probe-এর ফল যেন কখনো train-এ দেখা text-এ না হয়।
D17	Implicit benchmark এক corpus থেকে	মেশালে model উৎস চিনে নম্বর পায় (0.91 separability)।
D18	Multi-source benchmark-এ প্রতিটা source-এর ভেতরেও score	উৎস চেনার শর্টকাট ধরা পড়ে।
D19	Out-of-sample distillation: transfer set + committee as labeller + মুখস্থ-না-করা reliability	F28/F29 যে mechanism দেখিয়েছে, তার সরাসরি প্রতিকার। ১৪ নম্বর অংশ।

৮. Kaggle-এ চালানোর ইতিহাস

Version	তারিখ	কী হয়েছিল	GPU সময়
notebook58ee..., v3	১১ সেপ্টেম্বর	Teacher train: BERT-large 0.8973, irony 0.8926, HateBERT 0.8887 (stop rule পাস)। DeBERTa-v3-base NaN-এ collapse করে; fp32 loading আর NaN guard দিয়ে ঠিক। Driver students stage-এ crash (attribute clash); smoke test যোগ।	~৩ ঘণ্টা
d738 V1	১৩ সেপ্টেম্বর	পূর্ণ grid: ১২০ run (৫ student × ৪ mode × ৩ seed + hetero committee + ablation + sweep)। এর output-এই সব weight আছে; পরের version-গুলো এখান থেকে resume করে।	8.24 ঘণ্টা
d738 V2	১২ সেপ্টেম্বর	fp16 control চলেছে (mixed precision-এর দাম: BERT-mini 0.0014, BERT-small 0.0011)। তারপর cache stage-এ ৮৭ মিনিটে মারা যায়: resume teacher-দের weight ফেলে দিয়েছিল। ঠিক করা হয়েছে।	~১.৫ ঘণ্টা নষ্ট
d738 V3	১৬ সেপ্টেম্বর	৩৪ মিনিটে একটা extra fp16-check cell-এ log আটকে যায় (progress bar-এর pipe block), session ১২ ঘণ্টা idle থেকে kill হয়। কিছুই তৈরি হয়নি। শিক্ষা: log প্রত্যাশিত সময়ের অনেক পরেও না এগোলে cancel। প্রতিকার: driver এখন output ফাইলে লেখে, ২ ঘণ্টা চুপ থাকলে নিজেই kill করে।	১২ ঘণ্টা নষ্ট
d738 V4	১৭ সেপ্টেম্বর	Specialist train (implicit benchmark-এ 0.6029, tweets-এ adapt করে 0.8931), spec committee ৩ seed, ২টা control, τ 0.05/0.1/0.2, ২৬টা model-এ implicit analysis, tweets→implicit transfer, weight routing। ১৩১ run।	1.41 ঘণ্টা
d738 V5 (সামনে)	—	Transfer set (out-of-sample distillation), ৫ arm × ৩ seed; per-committee routing; ছোট τ run-গুলোর AUC।	~২.৫ ঘণ্টা (আনুমানিক)

Laptop-এ (CPU) আলাদা কিছু run হয়েছে (BERT-mini fine-tune-only, Wikipedia)। কিন্তু একই code, data আর seed-এ laptop আর Kaggle-এর ফল 0.0386 আলাদা আসে (৯.১০ দেখুন), তাই পেপারের প্রতিটা সংখ্যা শুধু Kaggle থেকে; laptop-এর সংখ্যা কখনো মেশানো হয় না।

৯. ফলাফল, সংখ্যাসহ

৯.১ Teacher-রা bar পার করেছে

Teacher	Macro-F1	Accuracy	Benign-sarcasm FPR	Irony-abuse recall
BERT-large	0.8973	0.9075	0.224	0.585
Implicit specialist (adapted)	0.8931	0.9043	0.263	0.678
RoBERTa-irony (adapted)	0.8926	0.9050	0.294	0.718
HateBERT (adapted)	0.8887	0.9011	0.317	0.696
DeBERTa-v3-base	0.8720	0.8867	0.409	0.773
TF-IDF + logistic regression (floor)	0.8798	0.8930	—	—

আগে থেকে ঠিক করা stop rule ছিল: অন্তত একজন adapted teacher fine-tune-only student-কে হারাতে হবে, নইলে distillation-এর দেওয়ার কিছু নেই। চারজনের তিনজন হারায়, তিনজন floor-ও পার করে। DeBERTa floor-এর নিচে; শুধু heterogeneous পরীক্ষার জন্য রাখা। লক্ষ করুন: যে teacher-এর FPR বেশি, তার recall-ও বেশি; মানে তারা বেশি “fire” করে, বেশি বোঝে না (৯.৬)।

৯.২ Distillation সবাইকে একটু বাড়ায়, কিন্তু প্রমাণের চেয়ে কম

Student	Params	Fine-tune only	Single-teacher	Uniform	D-MTHD	Uniform + DeBERTa	D-MTHD + DeBERTa
BERT-mini	11.2M	0.8393	0.8405	0.8385	0.8378	0.8378	0.8373
BERT-small	28.8M	0.8469	0.8488	0.8505	0.8471	0.8509	0.8477
DistilBERT	67.0M	0.8907	0.8963	0.8960	0.8960	0.8975	0.8966
DeBERTa-v3-xsmall	70.8M	0.8825	0.8865	0.8862	0.8833	0.8847	0.8828
BiLSTM	10.4M	0.8693	0.8748	0.8761	0.8732	0.8760	0.8764

Student	Best configuration	Gain over fine-tune only	95% CI
BERT-mini	Single-teacher	+0.0012	[−0.0057, +0.0079]
BERT-small	Uniform + DeBERTa	+0.0040	[−0.0058, +0.0126]
DistilBERT	Uniform + DeBERTa	+0.0068	[−0.0013, +0.0139]
DeBERTa-v3-xsmall	Single-teacher	+0.0040	[−0.0024, +0.0109]
BiLSTM	D-MTHD + DeBERTa	+0.0071	[−0.0039, +0.0195]

পাঁচটাই positive, যা Phase 2 পারেনি। কিন্তু **পাঁচটা interval-ই 0 ধরে**, আর distillation বনাম fine-tuning-এর ২৭টা তুলনার একটাও শূন্য বাদ দেয় না। 4,326টা test tweet-এ এত ছোট ফারাক প্রমাণ করা যায় না। লক্ষণীয়: সবচেয়ে ভিন্ন student (BiLSTM, transformer-ই নয়) সবচেয়ে বেশি পায়, আর teacher-দের সবচেয়ে কাছে student (BERT-mini) সবচেয়ে কম। **Homogeneity-র পক্ষে কোনো প্রমাণ নেই।** Efficiency-র দাবি এখানে: DistilBERT (67M) 0.8975 বনাম BERT-large (335M) 0.8973, পাঁচ ভাগের এক ভাগ parameter আর latency-তে।

৯.৩ Dynamic weighting সাধারণ গড়ের চেয়ে ভালো নয়, কোনো temperature-এই

Student	D-MTHD – uniform	95% CI	একই, DeBERTa সহ	95% CI
BERT-mini	−0.0007	[−0.0074, +0.0061]	−0.0005	[−0.0067, +0.0054]
BERT-small	−0.0034	[−0.0106, +0.0036]	−0.0032	[−0.0100, +0.0033]
DistilBERT	+0.0000	[−0.0079, +0.0082]	−0.0010	[−0.0087, +0.0069]
DeBERTa-v3-xsmall	−0.0029	[−0.0086, +0.0029]	−0.0019	[−0.0108, +0.0108]
BiLSTM	−0.0029	[−0.0116, +0.0056]	+0.0004	[−0.0072, +0.0081]

স্বাভাবিক আপত্তি ছিল: $\tau = 1$ -এ weight প্রায় সমান (0.332 / 0.337 / 0.331), তাই দুটো objective এক হওয়া অক্ষের ব্যাপার। তাই V4-এ $\tau = 0.05$ পর্যন্ত নামানো হয়েছে (BERT-mini, seed 1):

τ	Mean weight (BERT-large / HateBERT / irony)	Test macro-F1
0.05	0.318 / 0.356 / 0.326	0.8392
0.1	0.323 / 0.349 / 0.328	0.8388
0.2	0.327 / 0.344 / 0.329	0.8385
0.5	0.330 / 0.340 / 0.330	0.8390
1 (default)	0.332 / 0.337 / 0.331	0.8385
2	0.332 / 0.336 / 0.332	0.8390
5	0.333 / 0.334 / 0.333	0.8389
Uniform averaging	0.333 each	0.8372
Fine-tune only	—	0.8394

একশ গুণ temperature বদলেও score 0.0007-এর মধ্যে, আর প্রতিটা মানেই fine-tune-only-র নিচে। $\tau = 0.05$ -এও সবচেয়ে ভারী teacher গড়ে 0.356 weight পায়। Weight তীক্ষ্ণ হয় না কেন, তা ১০ নম্বর অংশে।

৯.৪ Implicit specialist আর দুটো control

Configuration (BERT-mini)	Seeds	Macro-F1	F1 on other_cyberbullying	Sarcasm AUC (seed 1)
Fine-tune only	3	0.8393 $\pm$ 0.0003	0.707	0.773
Uniform, homogeneous committee	3	0.8385 $\pm$ 0.0018	0.700	0.774
Uniform + implicit specialist	3	0.8390 $\pm$ 0.0035	0.699	0.768
D-MTHD, homogeneous committee	3	0.8378 $\pm$ 0.0011	0.705	0.773
D-MTHD + implicit specialist	3	0.8373 $\pm$ 0.0025	0.697	0.768
Control: specialist alone, no committee	1	0.8392	0.709	0.767
Control: pre-trained on the implicit corpus, no teacher	1	0.8377	0.705	0.756

Specialist যোগ করলে macro-F1 বদলায় +0.0005 [−0.0059, +0.0064] (uniform) আর −0.0005 [−0.0069, +0.0055] (D-MTHD)। Indirect abuse-এর class-এ F1 আর sarcasm AUC দুটোই সামান্য কমে। Control দুটোও ভালো করেনি: specialist একা fine-tune-only-র 0.0002-এর মধ্যে, আর implicit corpus-এ pre-train করা student ২৫টা model-এর মধ্যে সবচেয়ে কম AUC পায়। Weight routing দেখায় specialist-এর দিকে weight সামান্য ঝাঁকে (uniform 0.20-এর জায়গায় $\tau = 1$ -এ +0.009), কিন্তু HateBERT-এর দিকেও ততটাই (+0.011); অর্থাৎ এটা “implication চেনা” নয়, একটা class-এ ভালো fit করা।

৯.৫ Ablation আর sweep: শুধু pre-training-ই গুরুত্বপূর্ণ

BERT-mini, seed 1, পূর্ণ D-MTHD 0.8378-এর বিপরীতে: random initialised student 0.7905 (−0.0473); irony head ছাড়া 0.8364 (−0.0014); hidden term ছাড়া 0.8369 (−0.0009); uniform weight 0.8386 (+0.0008); per-batch weight 0.8389 (+0.0011)। Method-এর অংশ সরালে বড়জোর 0.0014 হারায়, দুটো ক্ষেত্রে বরং বাড়ে; pre-training সরালে 0.047 হারায়, বাকি সবের চল্লিশ গুণ। পুরো grid-এর ৫১টা (এখন ৬৬টা) তুলনার মধ্যে একমাত্র এই পার্থক্যটাই পরিসংখ্যানগতভাবে প্রমাণিত: −0.0488 [−0.0603, −0.0376]। Hyper-parameter-ও সমতল: $T \in \{1, 2, 8\} \rightarrow 0.8386 / 0.8402 / 0.8391$; $\alpha \in \{0.2, 0.6\} \rightarrow 0.8386 / 0.8394$; $\delta \in \{0.1, 0.5\} \rightarrow 0.8389 / 0.8399$ । DeBERTa teacher যোগ করলে পাঁচ student বদলায় −0.0005, +0.0006, +0.0032, −0.0005, +0.0006।

৯.৬ Discrimination pre-training-এ বাঁধা; recall শুধু “কত সহজে fire করে” মাপে

BERT-mini fine-tune-only, seed 1: ironic abuse-এ recall 0.91 যখন গালি আছে (৪৩টা item), 0.76 যখন নেই (1,517টা)। মানে model গালির ওপর কিছুটা ভর করে, কিন্তু গালি ছাড়া text-ও চারটার তিনটা ধরে; গালি-detector নয়। আসল সমস্যা discrimination: ironic abuse-এ গড় p(abusive) 0.748, নির্দোষ sarcasm-এ 0.449; দুটো distribution বড় করে overlap করে; AUC 0.773। 0.5 threshold-এ recall 0.792 আসে 39.5% false-positive-এর দামে, আর 0.90 পর্যন্ত

কোনো threshold-ই benign sarcasm-এর false positive 10%-এর নিচে নামাতে পারে না, ২৬টা model-এর একটাও।

২৫টা pre-trained BERT-mini variant (সব objective, committee, ৭টা τ , $T/\alpha/\delta$ sweep, সব ablation, দুটো control): sarcasm-discrimination AUC-এর গড় 0.771, standard deviation 0.005, range 0.756–0.777। Random init-এ 0.613। Irony head, যেটা এই মাপের জন্যই বানানো, band-এর ভেতরেই: ছাড়া 0.775, সহ 0.773। অথচ একই model-গুলোর 0.5 threshold-এর operating point অনেক নড়ে: recall 0.758–0.821, FPR 0.343–0.448, correlation +0.87।

Grid-এর ১৩৩টা model (teacher আর student, সব mode, সব seed): benign-sarcasm FPR আর ironic-abuse recall-এর correlation **+0.712**। Recall – FPR-এর গড় 0.357, sd মাত্র 0.051, অথচ আলাদা আলাদা করে দুটো 0.14–0.59 আর 0.54–0.81 range-এ ঘোরে। Architecture-এ পার্থক্য আসে (DistilBERT-এর FPR আর recall দুটোই সবচেয়ে কম, BERT-mini-র দুটোই সবচেয়ে বেশি), distillation mode-এ আসে না। সবচেয়ে খারাপ margin (0.082) random-init student-এর। **এজন্যই পেপার recall নয়, threshold-free AUC report করে।**

৯.৭ Implicit benchmark, আর tweets থেকে transfer

Model (implicit benchmark)	Macro-F1	not_hate F1	explicit_hate F1	implicit_hate F1	Implicit-discrimination AUC
Classical floor (TF-IDF)	0.5620	—	—	0.5562	0.7610
BERT-mini, fine-tune only	0.5549	0.8347	0.2857	0.5443	0.8196
HateBERT specialist	0.6029	0.8352	0.3662	0.6072	0.8247

ছোট student F1-এ n-gram-এর কাছে হারে (0.5549 বনাম 0.5620) কিন্তু ranking-এ অনেক এগিয়ে (AUC 0.8196 বনাম 0.7610)। দুটো মাপ উল্টো দিকে: model implication শিখেছে, কিন্তু সেটাকে decision-এ বদলাতে পারছে না। এটাই ৯.৬-এর যুক্তি, অন্য লোকের label-এ। explicit_hate class-এ মাত্র 864 training row, তাই macro-F1 এখানে headline নয়।

Transfer: tweets-এ train করা BERT-mini-কে কোনো training ছাড়া implicit benchmark-এর 2,064 test post-এ চালালে সে 81.0%-কে abusive বলে (আসল 35.7%); implicit hate বনাম not hate rank করে AUC **0.600**-এ, প্রায় আন্দাজ, অথচ একই architecture ওই corpus-এ train করলে 0.820। D-MTHD-ও একই (0.600)। Tweet student-রা abuse সম্পর্কে যা শিখেছে, তাতে “ইঙ্গিত কেন hateful” সেটা নেই।

৯.৮ Robustness (obfuscation)

BERT-mini, seed 1	Clean	Leetspeak	Character swap	Inserted spaces	Mixed
Fine-tune only	0.8394	0.7475	0.7417	0.7275	0.7116
D-MTHD	0.8385	0.7460	0.7361	0.7250	0.7077

বানানে কৌশল করলে ১২–১৩ পয়েন্ট পড়ে, distillation বাঁচায় না। এগুলো কৃত্রিম edit, মানুষের আসল evasion নয়; তাই “robust” শব্দটা শিরোনামে রাখা যাবে না (D9)।

৯.৯ Efficiency

Student	Params	Latency b1	Latency b32	GFLOPs/seq	fp32 size	INT8 size	INT8 macro-F1
BiLSTM	10.4M	2.57 ms	0.18 ms	~0	40 MB	32 MB	0.8736
BERT-mini	11.2M	3.47 ms	0.37 ms	0.87	43 MB	33 MB	0.8319
BERT-small	28.8M	3.74 ms	1.25 ms	3.36	110 MB	73 MB	0.8448
DistilBERT	67.0M	5.22 ms	3.72 ms	11.17	255 MB	132 MB	0.8931
DeBERTa-v3-xsmall	70.8M	23.49 ms	3.25 ms	10.57	270 MB	209 MB	0.8765
BERT-large (teacher)	335.1M	26.56 ms	21.65 ms	78.92	1,279 MB	—	—

DistilBERT BERT-large-এর সমান accuracy দেয় 5.1 গুণ কম parameter আর batch-32-এ 5.8 গুণ কম latency-তে; INT8 quantisation আকার অর্ধেক করে মাত্র 0.003-এর দামে। BERT-mini-র আকার 43 থেকে 33 MB-ই হয়, কারণ 11.2M-এর 7.8M parameter embedding table, যা dynamic quantisation ছোঁয় না।

৯.১০ দুই মেশিনে দুই ফল

একই code, data, seed আর hyper-parameter-এ BERT-mini fine-tune-only laptop CPU-তে 0.8779, Kaggle T4-তে 0.8393। যাচাই: mixed precision-এর দাম মাত্র 0.0014 (Kaggle fp32 0.8407); test label row-by-row এক; laptop-এ আবার চালালে ষোলো decimal পর্যন্ত একই ফল। Kaggle-এ model প্রথম epoch থেকেই ধীরে শেখে (loss 1.02 বনাম 0.87; validation 0.80 বনাম 0.84), তাই সন্দেহ library-র version (laptop-এ torch 2.14 / transformers 5.17, Kaggle-এ পুরোনো)। যাচাইয়ের উপায়: laptop-এ transformers 4.4x pin করে ৩০ মিনিটের একটা run। যতক্ষণ না হয়, Kaggle-এর BERT-mini/BERT-small-এর absolute সংখ্যা ৪ পয়েন্ট কম হতে পারে (এজন্যই দুটো floor-এর নিচে); grid-এর ভেতরের তুলনা বৈধ, কারণ সব run একই শর্তে।

১০. কেন কাজ করেনি: মাপা কারণ

১০.১ Teacher-রা task-এ মানিয়ে নেওয়ার পর প্রায় এক হয়ে যায় (F20, F23)

Teacher pair	Cohen's kappa	Disagreement	Error overlap
BERT-large, HateBERT	0.920	6.7%	0.710
BERT-large, irony	0.922	6.4%	0.712
HateBERT, irony	0.916	7.0%	0.673
BERT-large, DeBERTa-v3	0.893	8.9%	0.712
HateBERT, DeBERTa-v3	0.889	9.2%	0.673
irony, DeBERTa-v3	0.900	8.3%	0.730
HateBERT, implicit specialist	0.962	3.1%	0.843

চার teacher একসঙ্গে ঠিক হয় test set-এর 83.2%-এ, একসঙ্গে ভুল করে 4.7%-এ। Weighting শুধু সেখানেই কিছু করতে পারে যেখানে teacher-রা দ্বিমত করে, মানে এগারোটা একটা উদাহরণে; আর ভুলের দুই-তৃতীয়াংশে কোনো teacher-ই ঠিক নয়। Oracle (প্রতিটা উদাহরণে সঠিক teacher বাছতে পারলে) পৌঁছাত 0.9526 accuracy / 0.9469 macro-F1-এ; মানে ৫ পয়েন্ট headroom ছিল, কিন্তু আমাদের reliability signal তার কিছুই ধরতে পারে না। Specialist সবচেয়ে স্পষ্ট উদাহরণ: অন্য corpus-এ অন্য label-এ শিখে এসেও tweets-এ adapt করার পর সে HateBERT-এর প্রায় কপি (kappa 0.962)। **সারকথা: task adaptation তুলনায়োগ্যতা দেয়, কিন্তু diversity কেড়ে নেয়।** Cross-task যেকোনো committee এই দামে পড়বে।

১০.২ Reliability মাপা হচ্ছে এমন ডেটায়, যা teacher-রা মুখস্থ করে ফেলেছে (F28)

Weight হিসাব হয় training split-এ, আর teacher-দের fine-tune-ও হয়েছে ওই একই split-এ। শেষ epoch-এ তাদের training loss: BERT-large 0.033, HateBERT 0.059, irony 0.077, specialist 0.061, DeBERTa 0.227। অর্থাৎ যে ডেটায় weight পড়া হচ্ছে, সেখানে প্রতিটা teacher সঠিক label-কে প্রায় 1 probability দেয়; তাদের CE-র পার্থক্য কয়েক শতাংশ; তাই τ যত ছোটই হোক weight প্রায় সমান থাকে। যে teacher মুখস্থ করেনি (DeBERTa), শুধু তারই weight নড়ে। **Formula reliability মাপছে না, memorisation মাপছে।** এটা MT-BERT-সহ পুরো error-weighted multi-teacher family-র সমস্যা। আর এর দ্বিতীয় ফল আরও বড়: training split-এ teacher-দের soft label প্রায় one-hot gold label, তাই সেখানে distillation কার্যত সাধারণ fine-tuning-ই (Stanton et al. 2021, Beyer et al. 2022-এর জানা বিপদ)।

১০.৩ Committee-র দাম আছে, student পায় না (F29)

Committee	Best single teacher	Uniform mean	Best gold-free weighting	Stacked gate (5-fold CV)	Oracle accuracy
Homogeneous (3)	0.8973	0.9026	0.9023	0.9046	0.945
+ implicit specialist (4)	0.8973	0.9000	0.9011	0.9043	0.949
+ DeBERTa (4)	0.8973	0.9051	0.9055	0.9055	0.953
All five	0.8973	0.9036	0.9046	0.9041	0.955

Teacher-দের test probability থেকে সরাসরি হিসাব: committee-র সাধারণ গড় best teacher-কে +0.3 থেকে +0.8 macro-F1-এ হারায়। কিন্তু কোনো weighting, এমনকি teacher-দের output-এ train করা learned gate-ও, uniform-এর চেয়ে 0.003-এর বেশি পায় না: teacher-রা যেখানে দ্বিমত করে (10–14% item), তাদের probability বলে না কে ঠিক। তাই **learned routing / stacking পথটা বন্ধ; ঠিক করা reliability-র ceiling-ও +0.3।** আর student committee-র এই +0.5–0.8-এর কিছুই পায় না: committee বনাম single-teacher distillation পাঁচ student-এ -0.0019 , $+0.0017$, -0.0003 , -0.0003 , $+0.0014$ । একই 34,607টা text-এ ভালো label দিলে ভালো student হয় না। Student-এর দরকার বেশি text, যেখানে teacher-রা অনিশ্চিত; আর সেখানেই committee-র আসল কাজ: সে ভালো labeller। এই দুটো finding থেকেই ১৪ নম্বর অংশের পথ।

১১. সব finding এক নজরে (F1–F30)

#	এক লাইনে
F1	Tweet corpus যতটা ভাবা হয়, তার চেয়ে নোংরা: 1,563 text-এ একাধিক label, 507 duplicate; পরিষ্কার করলে val/test-এর ফারাক মিলিয়ে যায়।
F2	Teacher-রা floor পার করে; stop rule পাস।
F3	Distillation পাঁচ student-এরই score বাড়ায় (+0.0012 থেকে +0.0071), আর pre-training সবার চল্লিশ গুণ গুরুত্বপূর্ণ। (F27-এ সংশোধন: লাভ significant নয়।)
F4	67M student 335M teacher-এর 0.001-এর মধ্যে; efficiency-র দাবি এটাই।
F5	Wikipedia-তে ছোট student আগে থেকেই teacher-এর কাছে; distillation-এর জায়গা কম (laptop)।
F6	Dynamic weighting কোনো student-এ uniform-কে হারায় না।
F7	Heterogeneous student (DeBERTa-xsmall) দুর্বল আর ধীর।
F8	Obfuscation ছোট text-কে অনেক বেশি ক্ষতি করে (laptop)।
F9	Tweets আর Wikipedia একে অন্যে transfer হয় না (laptop; Kaggle-এ মাপা বাকি)।
F10	Indirect abuse miss হয় discrimination-এর জন্য, অন্ধত্বের জন্য নয়।
F11	INT8-এর লাভ model-এর আকারে নয়, গঠনে (embedding table)।
F12	Probe metric শুধু probe-এর domain-এই অর্থবহ।
F13	Implication label করা corpus-এ method-এর জায়গা আছে: floor AUC 0.761।
F14	দুই corpus hate নিয়ে একমত 99.7%, implication নিয়ে 48.2%।
F14b	ISHate-এর “subtlety” layer ব্যবহারযোগ্য নয়।
F15	দুই corpus-এর schema-য় দুটো ফাঁদ, যেকোনোটা চুপচাপ ভুল benchmark দেয়।
F16	দুই corpus মেশালে aggregate score বাড়ে, implicit hate-এর F1 কমে (উৎস-চেনার শর্টকাট)।
F17	একই code আর data দুই মেশিনে দুই ফল; পেপারের সব সংখ্যা এক মেশিন থেকে।
F18	Aggregation চুপচাপ দুটো আলাদা experiment গড় করছিল; ধরা পড়ে ঠিক হয়েছে।
F19	১৩৩ model-এর কেউ ভালো discriminate করে না; শুধু কত সহজে fire করে তাতে ফারাক।
F20	Committee যথেষ্ট diverse নয়; weighting-এর করার কিছু নেই।
F21	Specialist তৈরি; implicit-এর প্রথম সংখ্যা বলে metric-টা ঠিক বাছা হয়েছে।
F22	তীক্ষ্ণ weighting (τ 0.05–5) কিছু বদলায় না।
F23	Specialist tweets-এ সাহায্য করে না, control-ও না; কারণ kappa 0.962।
F24	Weight specialist-এর দিকে সামান্য ঝোঁকে, HateBERT-এর দিকেও ততটাই।
F25	Tweet student implication চেনে না: transfer AUC 0.600 বনাম 0.820।
F26	Results draft-এর দুটো অংশ laptop-এর সংখ্যা quote করছিল; Kaggle-এর সংখ্যায় একটা সিদ্ধান্ত বদলায় (model গালির ওপর কিছুটা ভর করে)।
F27	৫১টা তুলনার মধ্যে একটাই interval শূন্য বাদ দেয়: pre-training সরানো।
F28	Reliability মাপা হচ্ছে যেখানে teacher-রা label মুখস্থ করেছে; তাই signal saturated, আর $KD \approx$ fine-tuning।
F29	Committee best teacher-এর চেয়ে +0.5–0.8 ভালো, কোনো weighting তার ওপরে +0.003-এর বেশি নয়, student কিছুই পায় না।
F30	Kaggle-এর student প্রথম epoch থেকেই ধীরে শেখে; সন্দেহ library version।

১২. যা পারিনি (সং তালিকা)

- **Dynamic weighting:** কোনো τ -তেই uniform-এর চেয়ে ভালো নয়। Method-এর মূল দাবি টেকেনি।
- **Distillation-এর প্রমাণিত লাভ:** সব student-এ point estimate positive, কিন্তু কোনো CI শূন্য বাদ দেয় না।
- **Implicit specialist:** committee-তে, একা, বা pre-training হিসেবে কোনোভাবেই লাভ নেই।
- **Implication-এর discrimination বাড়ানো:** কোনো objective, committee, teacher বা head AUC নড়ায়নি।

- **Transfer:** tweets-এ শেখা model implicit hate প্রায় আন্দাজে চেনে।
- **Robustness:** obfuscation-এ ১২-১৩ পয়েন্ট পড়ে; distillation বাঁচায় না।
- **Homogeneity:** পক্ষে কোনো প্রমাণ নেই; বরং উল্টো ইঙ্গিত।
- **দুই মেশিনের ফারাক:** 0.0372-এর কারণ এখনো অজানা (সন্দেহ library version)।
- **এখনো বাকি:** Wikipedia-র Kaggle grid, implicit benchmark-এর student grid, ISHate out-of-domain মূল্যায়ন, human annotation (sheet ১১ সেপ্টেম্বর পাঠানো, ফেরত আসেনি), LLM baseline।

১৩. নতুন কী দিতে পারছি (novelty)

যা দাবি করা যায়:

- **Threshold-free audit:** ১৩৩ model-এ প্রমাণ যে recall@threshold “কত সহজে fire করে” মাপে; আর ২৫ variant-এ প্রমাণ যে distillation-এর কোনো রূপ (weighting, committee, specialist, pre-training) implication-এর discrimination বাড়ায় না, শুধু pre-training-ই দেয়।
- **Mechanism, মাপা:** “task adaptation comparability দেয়, diversity কেড়ে নেয়” (kappa 0.89–0.96); reliability signal training data-য় saturated (F28); committee-র +0.5–0.8 student পায় না (F29)। এগুলো পুরো error-weighted multi-teacher family-র ওপর খাটে, শুধু আমাদের ওপর নয়।
- **Data contribution:** এক উৎসের implicit benchmark, উৎস-চেনার ফাঁদের প্রমাণ (0.91 separability, 0.473 বনাম 0.548), দুই corpus-এর 48.2% একমত, per-row manifest দিয়ে text redistribute না করেই যাচাইযোগ্য rebuild।
- **Practice:** 67M student 335M teacher-এর সমান, INT8-এ আকার অর্ধেক।

যা নতুন নয়, দাবি করা যাবে না: D-MTHD method নিজে (MT-BERT-এর কাছাকাছি); “homogeneous” শব্দটা; efficiency-র ফল (কাজের, কিন্তু নতুন নয়)।

১৪. পেপারের framing, আর এখন যে পথে হাঁটছি

তিনটা option ছিল (paper/OPEN_DECISIONS.md, Decision 1)। **A:** মূল শিরোনাম রাখা, D-MTHD-ই contribution। বন্ধ, কারণ weighting কোনো τ -তেই কাজ করে না। **B:** implication ঘিরে method paper (“Teaching a small model to read implication”)। বাজি ছিল specialist কাজ করবে; tweets-এ করেনি। **B2:** একই বিষয়, কিন্তু measurement হিসেবে: “Distillation Does Not Teach Implication: A Threshold-Free Audit of Multi-Teacher Knowledge Distillation for Abusive Language Detection”। এর প্রতিটা দাবি মাপা হয়ে গেছে, MT-BERT-এর ঝুঁকি নেই, আর implicit grid-এর ফল যা-ই আসুক টেকে। এই পেপারটা পুরো লেখা আছে branch paper-b2-audit-এ (paper/PAPER.md, ৯,০০০+ শব্দ, ৬৩টা যাচাই করা reference)। দুর্বলতা: method-চাওয়া journal (ESWA, KBS) negative result কম নেয়; IPM বা ACL/EMNLP Findings বেশি মানানসই।

Mahdi-র সিদ্ধান্ত (১৭ সেপ্টেম্বর): শুধু negative result নয়, KD-র ভেতরে থেকেই positive result চাই। B2 branch-এ থাকল, আর সবচেয়ে সম্ভাবনাময় পথে কাজ শুরু।

যে পথ বেছেছি: out-of-sample distillation (D19)

F28 আর F29 একটা lever দেখায়, যা এই grid-এ কখনো ছিল না:

student কোন ডেটায় committee-কে নকল করে।

Training split-এ teacher-রা সব জানে, তাই শেখানোর কিছু নেই। Teacher-রা যে text দেখেনি, সেখানে তাদের soft label তথ্যবহুল, তাদের দ্বিমত সত্যি, আর committee একা teacher-এর চেয়ে ভালো labeller। ছোট student-এর বড় লাভ literature-এ (TinyBERT, Tang et al. 2019, Turc et al. 2019) এখান থেকেই আসে।

• Transfer set:

42,013টা unlabelled in-domain tweet (OLID, HatEval, Davidson corpus-এর text, label ছাড়া; আর আমাদের বাদ দেওয়া conflicting-label tweet)। Irony teacher-এর নিজের training data (SemEval-2018) আর Founta (provenance rule) বাদ। সব split, probe আর implicit benchmark-এর সঙ্গে dedupe (ISHate HatEval ধারণ করে, তাই ~10,000 বাদ পড়েছে)।

- **Training:**

transfer row-এ gold label নেই, তাই CE বাদ; student শুধু committee-র soft label (KL) আর hidden state থেকে শেখে।

- **ঠিক করা reliability (kNN):**

প্রতিটা teacher-এর reliability = validation set-এর (যেখানে সে train করেনি) ২০টা নিকটতম text-এ তার accuracy, তার নিজের representation space-এ। Gold label লাগে না, মুখস্থ করা সম্ভব নয়। এটাই F28-এর সরাসরি সমাধান।

- **৫টা arm, BERT-mini, ৩ seed:**

skd_transfer (এক teacher), uniform_transfer (committee, মূল বাজি), uniform_hetero_transfer (DeBERTa সহ, সেরা labeller), dmthd_knn_transfer (ঠিক করা weighting), pseudo_transfer (committee-র hard label দিয়ে শুধু CE: “soft label-এর জ্ঞান” না “শুধু বেশি ডেটা”, সেটা আলাদা করার control)।

আগেই লেখা prediction:

(১) uniform_transfer fine-tune-only-কে ≥ 0.010 -এ হারাবে, CI শূন্য বাদ দেবে —

এটাতেই পথ টেকে বা পড়ে

; (২) committee একা teacher-এর চেয়ে ভালো labeller; (৩) kNN weighting uniform-এর ওপরে $\leq +0.003$ (F29-এর ceiling); (৪) hard pseudo-label soft-এর চেয়ে কম পায়; (৫) sarcasm AUC 0.756–0.777-এই থাকে।

খরচ:

~২.৫ GPU-ঘণ্টা, tweets notebook-এর একটা resumed session (V5)।

মানে:

(১) টিকলে পেপারের positive result আছে, আর audit ব্যাখ্যা করে কেন in-sample grid কিছু পায়নি: দুটো মিলে আলাদা আলাদার চেয়ে শক্ত পেপার। না টিকলে audit-এ একটা মাপা negative যোগ হয়, B2 branch-ই পেপার।

১৫. Q1 journal-এর জন্য কী লাগে, কোথায় আছি, ঝুঁকি

Q1 requirement	অবস্থা
স্পষ্ট, defensible contribution	Framing-এর সিদ্ধান্তের ওপর নির্ভর করে; B2 তৈরি, V5-এর ফলে B-এর দিকে যেতে পারে
২-৩টা dataset-এ পূর্ণ experiment	শুধু tweets পূর্ণ; implicit grid আর Wikipedia বাকি
Control, ablation, multi-seed, significance test	সম্পন্ন
ফলের ব্যাখ্যা (mechanism)	সম্পন্ন (F19, F20, F23, F28, F29)
সাম্প্রতিক শক্ত baseline, zero-shot LLM সহ	হয়নি; reviewer প্রায় নিশ্চিত জিজ্ঞেস করবে
Human-verified test set, inter-annotator agreement	Annotator-দের কাছে আটকে (sheet ১১ সেপ্টেম্বর থেকে)
Thematic, সাম্প্রতিক related work	Skeleton আছে, prose বাকি
Reproducibility: code, manifest, checkpoint	Code public, manifest তৈরি; checkpoint release বাকি
Ethics, data, limitations statement	Draft আছে
দাবির সঙ্গে মিল রাখা introduction আর abstract	Framing-এর অপেক্ষায় (তিনটা abstract লেখা আছে)
Overclaim না করা	পুরো কাজে মানা হয়েছে

ঝুঁকি: (১) negative result-এর গ্রহণযোগ্যতা: method-চাওয়া journal-এ কঠিন, IPM/Findings-এ সম্ভব; (২) GPU সময়: implicit grid ৮-১০ ঘণ্টা, Wikipedia আরও; Kaggle-এ account-প্রতি সপ্তাহে ৩০ ঘণ্টা; (৩) annotator; (৪) LLM baseline না থাকা; (৫) দুই মেশিনের ফারাক reviewer-এর প্রশ্ন হবে, খোলাখুলি লেখা আছে; (৬) label-এর 48.2% একমত সব implicit ফলের সীমা; (৭) licence: IHC/ISHate-এর text re-host করা যাবে না, তাই শুধু manifest; (৮) submission deadline এখনো ঠিক হয়নি।

১৬. সামনের কাজ, আর team-এর কাছে যা দরকার

1. **Tweets notebook V5 চালানো** (V4-এর output input হিসেবে দিয়ে): transfer set-এর ৫ arm, ~২.৫ ঘণ্টা। ফল এলে scripts/transfer_verdict.py পাঁচটা prediction-এর PASS/FAIL দেয়।
2. **Implicit notebook চালানো** (kaggle/dmthd_implicit.ipynb, ৮-১০ GPU-ঘণ্টা): এখানে তিন teacher-ই implication শিখে আসা, distillation-এর জন্য সবচেয়ে ন্যায্য সুযোগ। ISHate out-of-domain মূল্যায়নও এতেই হবে। B2-এর prediction: implicit-discrimination AUC নড়বে না; নড়লে পেপার constructive হয়।
3. **Wikipedia, Kaggle-এ**, শুধু headline student আর disagreement-aware variant: laptop-এর সংখ্যা বদলাতে।
4. **Laptop-এ ৩০ মিনিটের একটা run** transformers 4.4x pin করে: দুই মেশিনের ফারাকের কারণ (F30)।
5. **Zero-shot LLM baseline**, ২,০০০টা নমুনায়: reviewer-এর প্রশ্ন আগেই সামলাতে (API budget বা Kaggle-এ open model, সিদ্ধান্ত দরকার)।
6. **Annotation:** ৩০০ item-এর sheet annotator-দের কাছে; মনে করিয়ে দেওয়া দরকার।
7. **Framing আর venue:** supervisor-দের সঙ্গে B2 (বা V5 টিকলে constructive B) আর IPM/Findings-এর সিদ্ধান্ত। Deadline ঠিক করা।
8. **লেখা:** framing ঠিক হলে introduction, abstract, related work, statements।

১৭. কোথায় কী আছে (repository: github.com/mahdihassanshadi/THESIS)

কী	কোথায়
প্রতিটা run আর সংখ্যার কালানুক্রমিক record	LOG.md
Glossary, সিদ্ধান্ত D1–D19, finding F1–F30, কী দাবি করা যায়/যায় না, open question	DECISIONS.md
Team-এর নেওয়ার মতো সিদ্ধান্ত, option আর যুক্তিসহ	paper/OPEN_DECISIONS.md
Results draft (১৭ সেপ্টেম্বর), তিনটা abstract, method, setup, related work, statements	paper/results_draft.md, abstract_draft.md, method_draft.md, setup_draft.md, related_work_draft.md, statements_draft.md
পূর্ণ manuscript (B2 framing)	branch paper-b2-audit: paper/PAPER.md
সব table (কোড থেকে তৈরি), ৬৬টা তুলনার significance table	paper/tables/
Q1 checklist, evidence pointer সহ	paper/q1_checklist.md
Kaggle notebook আর driver	kaggle/dmthd_tweets.ipynb, dmthd_implicit.ipynb, dmthd_wikipedia.ipynb, run_benchmark.py
Code: data prep, teacher/student training, evaluation, analysis	src/dmthd/
Test আর smoke script (push-এর আগে চলে)	scripts/
Probe set, annotation kit, corpus manifest	probes/, annotation/, paper/manifests/
যাচাই করা bibliography (৬৩ entry)	paper/references.bib

এই document-এর উৎস: paper/briefing/team_briefing_2026-09-20.html। প্রতিটি সংখ্যা repository-র table থেকে; কোনো সংখ্যা স্মৃতি থেকে লেখা নয়।